rotina_final_1997

January 23, 2016

1 Setup Inicial

2 Definindo Loggers

Define os loggers

Estes 'loggers' serão utilizados para salvar as saídas (outputs) em um arquivo de texto no diretório 'outputs'.

 ${\bf ref:} \qquad {\rm http://stackoverflow.com/questions/17035077/python-logging-to-multiple-log-files-from-different-classes}$

ATENÇÃO: RODAR O BLOCO ABAIXO APENAS UMA VEZ, SE ESTE BLOCO FOR EXECUTADO MAIS DE UMA VEZ OS LOGS SERÃO DUPLICADOS.

```
In []: log_formatter = logging.Formatter('%(asctime)s | %(levelname)s: %(message)s')
       log_output = logging.getLogger('log_output')
       FH_output = logging.FileHandler(
                                    'outputs/1997_output.log', mode='w')
       FH_output.setFormatter(log_formatter)
       log_output.setLevel(logging.INFO)
       log_output.addHandler(FH_output)
       log_output.propagate = False
        # Este logger (log_tela) loga na tela e também
        # no arquivo de output, junto com o conteúdo do
        # logger log_output
        log_tela = logging.getLogger('log_tela')
       SH_tela = logging.StreamHandler()
       SH_tela.setFormatter(log_formatter)
        log_tela.addHandler(SH_tela)
        log_tela.addHandler(FH_output)
        log_tela.setLevel(logging.INFO)
        log_tela.propagate = False
```

3 Funções de 1997

3.1 Funções gerais assessórias

Função	Status
consulta_refext	OK
verifica_dummy	OK
verifica_range	OK
pre_processamento	OK
coordenadas	OK

```
In [ ]: log_tela.info('Definindo as funções gerais assessórias')
       log_output.info('\n\n=======\n')
       def verifica_dummy(df, variavel):
            Verifica se uma variável, dummy, contém algum valor diferente de 0 ou de 1.
            :param df: dataframe com os dados a serem verificados
            :param variavel: string com o nome da variável (coluna) que tem os dados
                           que devem ser verificados.
            :return: Sem retorno, apenas salva as avaliações nos logs.
               verifica_dummy(dataframe, 'coluna a ser verificada')
           contador_de_erros = 0
           log_tela.info('Verificando a variável Dummy: ' + variavel)
           df_erros = df[(df[variavel]!=0) & (df[variavel]!=1)]
           if len(df_erros[variavel].value_counts()) > 0:
               log_tela.warning(variavel + ": " +
                               str(len(df_erros[variavel].value_counts())) +
                               " erros encontrados:\n" +
                               str(df_erros[variavel].value_counts()))
           else:
               log_tela.info(variavel + ": Nenhum erro encontrado.")
       def verifica_range(df, variavel, valor_menor, valor_maior):
            Verifica se uma variável, do tipo número inteiro, contém algum valor menor
            que "valor_menor" ou maior que "valor_maior".
            : param\ df:\ dataframe\ com\ os\ dados\ a\ serem\ verificados
            :param variavel: string com o nome da variável (coluna) que tem os dados
                           que devem ser verificados
            :param valor_menor: Valor mínimo esperado na variável (int ou float)
            :param valor_maior: Valor máximo esperado na variável (int ou float)
            :return: Sem retorno, apenas salva as avaliações nos logs.
           Uso:
               verifica_range(dataframe, 'nome_variavel', valor_menor, valor_maior)
```

```
log_tela.info('Verificando Range da variável: ' + variavel)
    # Obs: Registros inválidos: None (equivalente a NA)
   nulos = df[variavel].isnull().sum()
    nulos = nulos if nulos else 0
    log_output.info('\n\n' +
                    - ' + 'Minimo esperado: ' + str(valor_menor) + '\n' +
                     - ' + 'Máximo esperado: ' + str(valor_maior) + '\n' +
                     - ' + 'Total de registros: ' + str(len(df[variavel])) +
                     - ' + 'Registros nulos (NA): ' +
            str(df[variavel].isnull().sum()) + '\n'
    )
    df_erros = df[(df[variavel] < valor_menor) | (df[variavel] > valor_maior)]
    if len(df_erros[variavel].value_counts()) > 0:
        result = df_erros[variavel].value_counts().sort_index()
        # Verificando limite inferior
        if result.first_valid_index() < valor_menor:</pre>
            log_tela.warning(
                    variavel + ': ' + 'Valor inteiro mínimo encontrado: ' +
                    str(result.first_valid_index()) + ' - abaixo do esperado!')
        # Verificando limite superior
        if result.last_valid_index() > valor_maior:
            log_tela.warning(
                    variavel + ': ' + 'Valor inteiro máximo encontrado: ' +
                    str(result.last_valid_index()) + " - acima do esperado!")
        log_tela.warning(variavel + ': ' +
                                str(len(df_erros[variavel].value_counts())) +
                                ' valor(es) incorreto(s) ' +
                                'encontrado(s) nesta variável:\n' +
                                str(df_erros[variavel].value_counts()))
    else:
        log_tela.info(variavel + ": Nenhum erro encontrado.")
def pre_processamento(df):
    Realiza algumas ações prévias ao processamento dos dados,
    removendo alguns registros e ajustando o dataframe.
    log_tela.info('Criando/Renomeando colunas no dataframe principal')
    log_output.info('Renomeando coluna UCOD para UCOD_DOM')
    df.rename(columns={'UCOD':'UCOD_DOM'}, inplace=True)
    log_output.info('Renomeando coluna ANDA_CHEG para ANDA_DEST')
    df.rename(columns={'ANDA_CHEG':'ANDA_DEST'}, inplace=True)
    log_tela.info('Verificando se todas as variaveis esperadas'+
```

11 11 11

```
'existem no dataframe.\n' +
             'Caso não exista alguma, ela é criada.')
variaveis = ['ANO', 'CD_ENTRE', 'DIA_SEM', 'UCOD_DOM', 'ZONA_DOM',
            'SUBZONA_DOM', 'MUN_DOM', 'CO_DOM_X', 'CO_DOM_Y', 'ID_DOM',
            'F_DOM', 'FE_DOM', 'NO_DOM', 'TIPO_DOM', 'TOT_FAM', 'ID_FAM'
            'F_FAM', 'FE_FAM', 'NO_FAM', 'COND_MORA', 'QT_AUTO', 'QT_BICI',
            'QT_MOTO', 'CD_RENFAM', 'REN_FAM', 'ID_PESS', 'F_PESS',
            'FE_PESS', 'NO_PESS', 'SIT_FAM', 'IDADE', 'SEXO', 'ESTUDA',
            'GRAU_INSTR', 'OCUP', 'SETOR_ATIV', 'CD_RENIND', 'REN_IND',
            'UCOD_ESC', 'ZONA_ESC', 'SUBZONA_ESC', 'MUN_ESC', 'CO_ESC_X',
            'CO_ESC_Y', 'UCOD_TRAB1', 'ZONA_TRAB1', 'SUBZONA_TRAB1',
            'MUN_TRAB1', 'CO_TRAB1_X', 'CO_TRAB1_Y', 'UCOD_TRAB2',
            'ZONA_TRAB2', 'SUBZONA_TRAB2', 'MUN_TRAB2', 'CO_TRAB2_X',
            'CO_TRAB2_Y', 'ID_VIAG', 'F_VIAG', 'FE_VIAG', 'NO_VIAG',
            'TOT_VIAG', 'UCOD_ORIG', 'ZONA_ORIG', 'SUBZONA_ORIG',
            'MUN_ORIG', 'CO_ORIG_X', 'CO_ORIG_Y', 'UCOD_DEST', 'ZONA_DEST',
            'SUBZONA_DEST', 'MUN_DEST', 'CO_DEST_X', 'CO_DEST_Y',
            'DIST_VIAG', 'SERV_PAS_ORIG', 'SERV_PAS_DEST', 'MOTIVO_ORIG',
            'MOTIVO_DEST', 'MODO1', 'MODO2', 'MODO3', 'MODO4', 'MODO_PRIN',
            'TIPO_VIAG', 'H_SAIDA', 'MIN_SAIDA', 'ANDA_ORIG', 'H_CHEG',
            'MIN_CHEG', 'ANDA_DEST', 'DURACAO', 'TIPO_EST_AUTO',
           'VALOR_EST_AUTO']
for variavel in variaveis:
   if variavel not in df.columns:
        # Se a variável não existe no dataframe então ela é criada
            # com valor padrão de NONE (NA)
       df[variavel] = None
       log_tela.info('Criando a variavel ' + variavel + ' no dataframe')
log_output.info('Reordenando as variáveis')
df = df[['ANO', 'CD_ENTRE', 'DIA_SEM', 'UCOD_DOM', 'ZONA_DOM',
            'SUBZONA_DOM', 'MUN_DOM', 'CO_DOM_X', 'CO_DOM_Y', 'ID_DOM',
            'F_DOM', 'FE_DOM', 'NO_DOM', 'TIPO_DOM', 'TOT_FAM', 'ID_FAM',
            'F_FAM', 'FE_FAM', 'NO_FAM', 'COND_MORA', 'QT_AUTO', 'QT_BICI',
           'QT_MOTO', 'CD_RENFAM', 'REN_FAM', 'ID_PESS', 'F_PESS',
           'FE_PESS', 'NO_PESS', 'SIT_FAM', 'IDADE', 'SEXO', 'ESTUDA',
            'GRAU_INSTR', 'OCUP', 'SETOR_ATIV', 'CD_RENIND', 'REN_IND',
            'UCOD_ESC', 'ZONA_ESC', 'SUBZONA_ESC', 'MUN_ESC', 'CO_ESC_X',
            'CO_ESC_Y', 'UCOD_TRAB1', 'ZONA_TRAB1', 'SUBZONA_TRAB1',
            'MUN_TRAB1', 'CO_TRAB1_X', 'CO_TRAB1_Y', 'UCOD_TRAB2',
            'ZONA_TRAB2', 'SUBZONA_TRAB2', 'MUN_TRAB2', 'CO_TRAB2_X',
            'CO_TRAB2_Y', 'ID_VIAG', 'F_VIAG', 'FE_VIAG', 'NO_VIAG',
            'TOT_VIAG', 'UCOD_ORIG', 'ZONA_ORIG', 'SUBZONA_ORIG',
            'MUN_ORIG', 'CO_ORIG_X', 'CO_ORIG_Y', 'UCOD_DEST', 'ZONA_DEST',
            'SUBZONA_DEST', 'MUN_DEST', 'CO_DEST_X', 'CO_DEST_Y',
            'DIST_VIAG', 'SERV_PAS_ORIG', 'SERV_PAS_DEST', 'MOTIVO_ORIG',
            'MOTIVO_DEST', 'MODO1', 'MODO2', 'MODO3', 'MODO4', 'MODO_PRIN',
            'TIPO_VIAG', 'H_SAIDA', 'MIN_SAIDA', 'ANDA_ORIG', 'H_CHEG',
            'MIN_CHEG', 'ANDA_DEST', 'DURACAO', 'TIPO_EST_AUTO',
            'VALOR_EST_AUTO']]
log_output.info('\n\n=======\n')
log_output.info('\n\n=======\n')
```

return df

```
def coordenadas(passo, df):
    Itera sobre os registros do dataframe coords,
        a cada iteração, utiliza o valor das colunas ZONA e SUBZONA
        para filtrar o dataframe df em cada um dos tipos de ZONA E
        SUBZONA (DOM, ESC, TRAB1, TRAB2, ORIG, DEST) e substitui os valores
        das coordenadas X e Y de cada tipo (CO_DOM_X, CO_ESC_Y, etc) com
        os valores das colunas CO_X e CO_Y do dataframe coords.
    :param passo: número do passo para o log
    :param df: Dafaframe a ser modificado (ex.: od1997)
    :return: retorna o dataframe modificado com todas as coordenadas aplicadas
    log_tela.info("### PASSO " + str(passo) + " - COORDENADAS")
    def coord_aux(row):
        Esta função irá receber uma linha (row) do dataframe coords e
            utilizar os valores desta linha para realizar as alterações
            de coordenadas no dataframe df.
        .....
        # Começando pelo tipo DOM, alterando CO_DOM_X e depois CO_DOM_Y
        df.loc[(df['ZONA_DOM'] == row['ZONA']) &
               (df['SUBZONA_DOM'] == row['SUBZONA']),'CO_DOM_X'] = row['CO_X']
        df.loc[(df['ZONA_DOM'] == row['ZONA']) &
               (df['SUBZONA_DOM'] == row['SUBZONA']),'CO_DOM_Y'] = row['CO_Y']
        # Agora com o tipo ESC, alterando CO_ESC_X e depois CO_ESC_Y
        df.loc[(df['ZONA_ESC'] == row['ZONA']) &
               (df['SUBZONA_ESC'] == row['SUBZONA']), 'CO_ESC_X'] = row['CO_X']
        df.loc[(df['ZONA_ESC'] == row['ZONA']) &
               (df['SUBZONA_ESC'] == row['SUBZONA']),'CO_ESC_Y'] = row['CO_Y']
        # Agora com o tipo TRAB1, alterando CO_TRAB1_X e depois CO_TRAB1_Y
        df.loc[(df['ZONA_TRAB1'] == row['ZONA']) &
               (df['SUBZONA_TRAB1'] == row['SUBZONA']), 'CO_TRAB1_X'] = row['CO_X']
        df.loc[(df['ZONA_TRAB1'] == row['ZONA']) &
               (df['SUBZONA_TRAB1'] == row['SUBZONA']),'CO_TRAB1_Y'] = row['CO_Y']
        # Agora com o tipo TRAB2, alterando CO_TRAB2_X e depois CO_TRAB2_Y
        df.loc[(df['ZONA_TRAB2'] == row['ZONA']) &
               (df['SUBZONA_TRAB2'] == row['SUBZONA']), 'CO_TRAB2_X'] = row['CO_X']
        df.loc[(df['ZONA_TRAB2'] == row['ZONA']) &
               (df['SUBZONA_TRAB2'] == row['SUBZONA']), 'CO_TRAB2_Y'] = row['CO_Y']
        # Agora com o tipo ORIG, alterando CO_ORIG_X e depois CO_ORIG_Y
        df.loc[(df['ZONA_ORIG'] == row['ZONA']) &
               (df['SUBZONA_ORIG'] == row['SUBZONA']),'CO_ORIG_X'] = row['CO_X']
        df.loc[(df['ZONA_ORIG'] == row['ZONA']) &
               (df['SUBZONA_ORIG'] == row['SUBZONA']), 'CO_ORIG_Y'] = row['CO_Y']
        # Agora com o tipo DEST, alterando CO_DEST_X e depois CO_DEST_Y
        df.loc[(df['ZONA_DEST'] == row['ZONA']) &
               (df['SUBZONA_DEST'] == row['SUBZONA']), 'CO_DEST_X'] = row['CO_X']
        df.loc[(df['ZONA_DEST'] == row['ZONA']) &
```

```
(df['SUBZONA_DEST'] == row['SUBZONA']),'CO_DEST_Y'] = row['CO_Y']
log_output.info('Lendo arquivo auxiliar de Coordenadas das subzonas')
coords = pd.read_csv('auxiliares/coord_subzonas_1997.csv', sep=';', decimal=',')

# Esta variável out não é utilizada para nada além de evitar um
# monte de output que não será utilizado e que é gerado pelo método apply.
out = coords.apply(coord_aux, axis=1)

log_output.info('\n\n========\n')
return df
```

3.2 Funções Gerais

Função/Variável	Status
passo_ano	OK
$passo_dia_sem$	OK
passo_ucods	OK

```
In []: log_tela.info('Definindo as funções gerais')
       log_output.info('\n\n======\n')
       def passo_ano(passo, df):
           Preenche a coluna "ANO" com valor 3 em todas células
           Categorias:
           /valor/ano_correspondente/
           |----|
           11/1977/
           [2]1987]
           |3|1997|
           14120071
           :param passo: Número do passo atual para registro/log
           :param df: dataframe a ser modificado
           :return: retorna o dataframe modificado
           log_tela.info("### PASSO " + str(passo) + " - ANO")
           # Definindo valor '3' para todas as células da coluna ANO
           df["ANO"] = 3
           return df
       def passo_dia_sem(passo, df):
           Apenas verificar os valores existentes
           # ####Categorias:
           # Valor/Descrição
           # -----
           # 2/Segunda-Feira
           # 3/Terça-Feira
           # 4/Quarta-Feira
           # 5/Quinta-Feira
           # 6/Sexta-Feira
           :param passo: Número do passo atual para registro/log
           :param df: dataframe a ser modificado
           :return: retorna o dataframe modificado
```

```
log_tela.info("### PASSO " + str(passo) + " - DIA_SEM")
   # Substituindo **0** por **None**
   df.loc[df['DIA_SEM']==0,'DIA_SEM'] = None
   # Verificando intervalo de valores - condições:
        # "DIA SEM >= 2" E "DIA SEM <= 6"
   verifica_range(df, 'DIA_SEM', 2, 6)
   log_output.info('\n\n========\n')
   return df
def passo_ucods(passo, df):
    Itera sobre os registros do dataframe ucods,
        a cada iteração, utiliza o valor da coluna ZONA_REF
       para filtrar o dataframe df em cada um dos tipos de ZONA
        (DOM, ESC, TRAB1, TRAB2, ORIG, DEST) e substitui o valor
       da respectiva UCOD.
    :param passo: número do passo para o log
    :param df: Dafaframe a ser modificado (ex.: od1997)
    :return: retorna o dataframe modificado com todas as UCODS aplicadas
   log_tela.info("### PASSO " + str(passo) + " - UCODS")
   def ucod_aux(row):
       df.loc[df['ZONA_DOM'] == row['ZONA_REF'],'UCOD_DOM'] = row['UCOD_BUSCADA']
       df.loc[df['ZONA_ESC'] == row['ZONA_REF'], 'UCOD_ESC'] = row['UCOD_BUSCADA']
       df.loc[df['ZONA_TRAB1'] == row['ZONA_REF'], 'UCOD_TRAB1'] = row['UCOD_BUSCADA']
       df.loc[df['ZONA_TRAB2'] == row['ZONA_REF'], 'UCOD_TRAB2'] = row['UCOD_BUSCADA']
       df.loc[df['ZONA_ORIG'] == row['ZONA_REF'], 'UCOD_ORIG'] = row['UCOD_BUSCADA']
       df.loc[df['ZONA_DEST'] == row['ZONA_REF'], 'UCOD_DEST'] = row['UCOD_BUSCADA']
   log_output.info('Lendo arquivo auxiliar UCOD')
   ucods = pd.read_csv('auxiliares/UCOD-1997.csv', sep=';', decimal=',')
   # Esta variável out não é utilizada para nada além de evitar um
   # monte de output que não será utilizado e que é gerado pelo método apply.
   out = ucods.apply(ucod_aux, axis=1)
   # Verificando intervalo de valores - condições:
        # "UCOD_XXX >= 1" E "UCOD_XXX <= 67"
   for tipo in ['DOM', 'ESC', 'TRAB1', 'TRAB2', 'ORIG', 'DEST']:
       verifica_range(df, 'UCOD_' + tipo, 1, 67)
   log_output.info('\n\n========\n')
   return df
```

3.3 Funções do Domicílio

Função/Variável	Status
passo_zona_dom	OK
$passo_subzona_dom$	OK
$passo_mun_dom$	OK
$passo_f_dom$	OK
$passo_fe_dom$	OK
passo_tipo_dom	ОК

```
In [ ]: log_tela.info('Definindo as funções do domicílio')
       log_output.info('\n\n=======\n')
       def passo_zona_dom(passo, df):
           Checar se existe algum erro
           # ####Categorias:
           # > 1 a 389
           [Teste: Checar se existe algum número < 1 ou > 389.
               Se encontrar, retornar erro indicando em qual linha.]
           :param passo: passo
           :param df: dataframe
           :return: sem retorno
           log_tela.info("### PASSO " + str(passo) + " - ZONA_DOM")
           # Substituindo valor O por None
           df.loc[df['ZONA_DOM']==0,'ZONA_DOM'] = None
           # Verificando intervalo de valores - condições:
                # "ZONA_DOM >= 1" E "ZONA_DOM <= 389"
           verifica_range(df, 'ZONA_DOM', 1, 389)
           log_output.info('\n\n=======\n')
           return df
       def passo_subzona_dom(passo, df):
           Checar se existe algum erro
           # ####Categorias:
           \# > 1 \ a \ 9
           [Teste: Checar se existe algum número < 1 ou > 9.
               Se encontrar, retornar erro indicando em qual linha.]
           :param passo: Número do passo atual para registro/log
```

```
:param df:
    :return: sem retorno
   log_tela.info("### PASSO " + str(passo) + " - SUBZONA_DOM")
   # Substituindo valor O por None
   df.loc[df['SUBZONA_DOM']==0, 'SUBZONA_DOM'] = None
   # Verificando intervalo de valores - condições:
       # "SUBZONA_DOM >= 1" E "SUBZONA_DOM <= 9"
   verifica_range(df, 'SUBZONA_DOM', 1, 9)
   log_output.info('\n\n========\n')
   return df
def passo_mun_dom(passo, df):
   Checar se existe algum erro
   # ####Categorias
   # > 1 a 39
    [Teste: Checar se existe algum número < 1 ou > 39.
       Se encontrar, retornar erro indicando em qual linha.]
   :param passo: Número do passo atual para registro/log
    :param df:
    :return: sem retorno
   log_tela.info("### PASSO " + str(passo) + " - MUN_DOM")
   # Substituindo valor O por None
   df.loc[df['MUN_DOM']==0,'MUN_DOM'] = None
   # Verificando intervalo de valores - condições:
       # "MUN_DOM >= 1" E "MUN_DOM <= 39"
   verifica_range(df, 'MUN_DOM', 1, 39)
   log_output.info('\n\n========\n')
   return df
def passo_f_dom(passo, df):
   Checar se existe algum erro na coluna "F_DOM"
   # ####Categorias
   # Valor/Descrição
   # ----
   # O/Demais registros
    # 1/Primeiro Registro do Domicílio
    [Teste: Checar se existe algum número diferente de 0 ou 1.
       Se encontrar, retornar erro indicando em qual linha.]
```

```
:param passo: Número do passo atual para registro/log
    :param df:
   :return: sem retorno
   log_tela.info("### PASSO " + str(passo) + " - F_DOM")
   verifica_dummy(df, 'F_DOM')
   log_output.info('\n\n========\n')
   return df
def passo_fe_dom(passo, df):
   Nada há que se fazer em relação aos dados da coluna "FE_DOM"
    :param passo: Número do passo atual para registro/log
   :param df:
   :return: sem retorno
   log_tela.info("### PASSO " + str(passo) + " - FE_DOM")
   log_output.info('\n\n========\n')
   return df
def passo_tipo_dom(passo, df):
   * Substituir **0** por **None (NA)**
   * Substituir **3** por **2**
    * Substituir **2** por **0**
   # ####Categorias anteriores / novas
   # Valor | Descrição
   # ----/---
   # 1/Particular
   # 2/Coletivo
   # 3/Favela
   # ####Categorias novas
   # Valor | Descrição
   # ----
   # OlColetivo
   # 1/Particular
    [Teste: Checar se existe algum número < 0 ou > 1.
       Se encontrar, retornar erro indicando em qual linha.]
    :param passo: Número do passo atual para registro/log
    :param df:
    : return:
   log_tela.info("### PASSO " + str(passo) + " - TIPO_DOM")
   df.loc[df['TIPO_DOM']==0,'TIPO_DOM'] = None
```

```
df.loc[df['TIPO_DOM']==3,'TIPO_DOM'] = 2
df.loc[df['TIPO_DOM']==2,'TIPO_DOM'] = 0

# Verificando intervalo de valores - condições:
    # "TIPO_DOM >= 0" E "TIPO_DOM <= 1"

verifica_dummy(df, 'TIPO_DOM')
log_output.info('\n\n========\n')</pre>
```

3.4 Funções da Família

```
Função/Variável
                  Status
                  OK
passo_tot_fam
passo_f_fam
                  OK
                  OK
passo_fe_fam
passo_cond_mora
                  OK
                  OK
passo_qt_auto
passo_qt_bici
                  OK
passo_qt_moto
                  OK
                  OK
passo_ren_fam
passo_cd_renfam
                  OK
```

```
In []: log_tela.info('Definindo as funções da família')
       log_output.info('\n\n=======\n')
       def passo_tot_fam(passo, df):
           Nada há que se fazer em relação aos dados da coluna "TOT_FAM"
           :param passo: Número do passo atual para registro/log
           :param df:
           :return: sem retorno
           log_tela.info("### PASSO " + str(passo) + " - TOT_FAM")
           log_output.info('\n\n======\n')
           return df
       def passo_f_fam(passo, df):
           Checar se existe algum erro na coluna "F_FAM"
           # ####Categorias
           # Valor/Descrição
           # ----
           # O/Demais registros
           # 1/Primeiro Registro da Família
           [Teste: Checar se existe algum número diferente de 0 ou 1.
              Se encontrar, retornar erro indicando em qual linha.]
           :param passo: Número do passo atual para registro/log
           :param df:
           :return:
           n n n
           log_tela.info("### PASSO " + str(passo) + " - F_FAM")
           verifica_dummy(df, 'F_FAM')
```

```
log_output.info('\n\n========\n')
   return df
def passo_fe_fam(passo, df):
   Nada há que se fazer em relação aos dados da coluna "FE_FAM"
    :param passo: Número do passo atual para registro/log
   :param df:
   :return:
   log_tela.info("### PASSO " + str(passo) + " - FE_FAM")
   log_output.info('\n\n========\n')
   return df
def passo_cond_mora(passo, df):
   Substituir valores da coluna "COND_MORA"
   * Substituir todos valores **5** por **0**
   * Substituir todos valores **0** por **None**
   * Substituir todos valores **4** por **3**
   #### Categorias anteriores
   Valor/Descrição
   ----/---
   1/Aluqada
   2/Própria
   3/Cedida
   4/Outros
   5/Não respondeu
   #### Categorias novas
   Valor/Descrição
   ----/---
   1/Aluqada
   2/Própria
   3/Outros
    [Teste: Checar se existe algum número < 1 ou > 3.
       Se encontrar, retornar erro indicando em qual linha.]
    :param passo: passo
    :param df: dataframe
   :return: dataframe modificado
   log_tela.info("### PASSO " + str(passo) + " - COND_MORA")
   # Substituindo valor 5 por 0
   df.loc[df['COND_MORA'] == 5, 'COND_MORA'] = 0
```

```
# Substituindo valor O por None
   df.loc[df['COND_MORA']==0,'COND_MORA'] = None
   # Substituindo valor 4 por 3
   df.loc[df['COND_MORA'] == 4, 'COND_MORA'] = 3
   # Verificando intervalo de valores - condições:
       # "COND_MORA >= 1" E "COND_MORA <= 3"
   verifica_range(df, 'COND_MORA', 1, 3)
   log_output.info('\n\n=======\n')
   return df
def passo_qt_auto(passo, df):
   Nada há que se fazer em relação aos dados da coluna "QT_AUTO"
   :param passo: Número do passo atual para registro/log
   :param df:
   :return:
   log_tela.info("### PASSO " + str(passo) + " - QT_AUTO")
   log_output.info('\n\n========\n')
   return df
def passo_qt_bici(passo, df):
   Não existe essa informação no banco de dados de 1997, logo,
       este campo será preenchido com 'None'.
    :param passo: Número do passo atual para registro/log
   :param df:
   :return: dataframe modificado
   df['QT_BICI'] = None
   log_tela.info('### PASSO ' + str(passo) + ' - QT_BICI')
   log_output.info('\n\n========\n')
   return df
def passo_qt_moto(passo, df):
   Não existe essa informação no banco de dados de 1997, logo,
       este campo será preenchido com 'None'.
   :param passo: Número do passo atual para registro/log
   :param df:
   :return: dataframe modificado
   df['QT_MOTO'] = None
   log_tela.info('### PASSO ' + str(passo) + ' - QT_MOTO')
   log_output.info('\n\n========\n')
```

return df

```
def passo_ren_fam(passo, df, deflator):
    Corrige a renda familiar de acordo com o deflator passado na função.
    :param passo: Número do passo atual para registro/log
    :param df: dataframe
    :param deflator: Deflator utilizado para correção da renda.
    :return: sem retorno
    log_tela.info("### PASSO " + str(passo) + " - REN_FAM")
    df['REN_FAM'] = df['REN_FAM'] * deflator
    return df
def passo_cd_renfam(passo, df):
    Substituir valores da coluna "CD_RENFAM"
    * Substituir todos valores **2** por **0**
    * Substituir todos valores **3** por **2**
    #### Categorias anteriores
    Valor/Descrição
    ----/---
    1/Renda familiar completa
    2/Não tem renda
    3/Renda familiar incompleta
    #### Categorias novas
    Valor/Descrição
    O/Renda Familiar Declarada como Zero
    1/Renda Familiar Declarada e Maior que Zero
    2/Renda Atribuída
    [Teste: Checar se existe algum número < 0 ou > 2.
        Se encontrar, retornar erro indicando em qual linha.]
    :param passo: Número do passo atual para registro/log
    :param df:
    :return: retorna o dataframe corrigido
    n n n
    log_tela.info("### PASSO " + str(passo) + " - CD_RENFAM")
    # Substituindo valor 2 por 0
    df.loc[df['CD_RENFAM'] == 2, 'CD_RENFAM'] = 0
    # Substituindo valor 3 por 2
    df.loc[df['CD_RENFAM']==3,'CD_RENFAM'] = 2
    # Dividindo a categoria '0', "Respondeu", em:
```

```
# - 0 "Renda Familiar Declarada como Zero" e
# - 1 "Renda Familiar Declarada e Maior que Zero"
df.loc[(df['CD_RENFAM'] == 0) &
       (df['REN_FAM'] != 0) &
       (df['REN_FAM'].notnull()), 'CD_RENFAM'] = 1
# Verificando intervalo de valores - condições:
    # "CD_RENFAM >= 0" E "CD_RENFAM <= 2"
verifica_range(df, 'CD_RENFAM', 0, 2)
log_output.info('\n\n======\n')
return df
```

3.5 Funções da pessoa

Função/Variável	Status
passo_f_pess	ОК
$passo_fe_pess$	OK
$passo_sit_fam$	OK
passo_idade	OK
passo_sexo	OK
passo_grau_instr	OK
passo_ocup	OK
passo_setor_ativ	OK
passo_ren_ind	OK
$passo_cd_renind$	OK
passo_estuda	Verificar

Obs.: Se ESTUDA for ser alterado pela verificação do ZONA_ESC, no main() ele deverá ser chamado após ZONA_ESC. Atualmente ele já está localizado após o ZONA_ESC na chamada do main(). Após confirmar o que será feito com ele, se for necessário alterar sua localização.

```
In []: log_tela.info('Definindo as funções da pessoa')
       log_output.info('\n\n=======\n')
       def passo_f_pess(passo, df):
          Checar se existe algum erro na coluna "F_PESS"
          # ####Categorias
          # Valor/Descrição
          # ----
          # O/Demais registros
          # 1/Primeiro Registro da Pessoa
          [Teste: Checar se existe algum número diferente de 0 ou 1.
              Se encontrar, retornar erro indicando em qual linha.]
          :param passo: Número do passo atual para registro/log
          :param df:
          : return:
          log_tela.info("### PASSO " + str(passo) + " - F_PESS")
          verifica_dummy(df, 'F_PESS')
          log_output.info('\n\n========\n')
          return df
       def passo_fe_pess(passo, df):
```

```
11 11 11
    Nada há que se fazer em relação aos dados das colunas "FE_PESS"
    :param passo: Número do passo atual para registro/log
    :param df:
    :return:
    .. .. ..
    log_tela.info("### PASSO " + str(passo) + " - FE_PESS")
    log_output.info('\n\n=======\n')
    return df
def passo_sit_fam(passo, df):
    Não é preciso realizar nenhuma alteração
    #### Categorias anteriores
    Valor/Descrição
    ----/---
    1/Chefe
    2/Cônjuge
    3/Filho(a)
    4/Parente / Agregado
    5/Empregado Residente
    6/Visitante não residente na RMSP
    #### Categorias novas:
    Valor/Descrição
    ----/---
    1/ Pessoa Responsável
    2/ Cônjuge/Companheiro(a)
    3/ Filho(a)/Enteado(a)
    4/ Outro Parente / Agregado
    5/ Empregado Residente
    6/ Outros (visitante não residente / parente do empregado)
    [Teste: Checar se existe algum número < 1 ou > 6.
       Se encontrar, retornar erro indicando em qual linha.]
    :param passo: Número do passo atual para registro/log
    :param df:
    :return: retorna o dataframe modificado
    log_tela.info("### PASSO " + str(passo) + " - SIT_FAM")
    # Verificando intervalo de valores - condições:
        # "SIT_FAM >= 1" E "SIT_FAM <= 6"
    verifica_range(df, 'SIT_FAM', 1, 6)
    log_output.info('\n\n========\n')
    return df
def passo_idade(passo, df):
```

```
Nada há que se fazer em relação aos dados da coluna "IDADE"
    :param passo: Número do passo atual para registro/log
   :param df:
   : return:
   log_tela.info("### PASSO " + str(passo) + " - IDADE")
   log_output.info('\n\n========\n')
   return df
def passo_sexo(passo, df):
   # ####Categorias anteriores
   # Valor/Descrição
   # ----
   # 0/Não Respondeu (-> None)
   # 1/Masculino
   # 2|Feminino
   # ####Categorias novas
   # Valor/Descrição
   # ----
   # OlMasculino
   # 1/Feminino
   [Teste: Checar se existe algum número diferente de 0 ou 1.
       Se encontrar, retornar erro indicando em qual linha.]
   :param passo: Número do passo atual para registro/log
   :param df:
    :return: retorna o dataframe modificado
    11 11 11
   log_tela.info("### PASSO " + str(passo) + " - SEXO")
   # Substituindo valor O por None
   df.loc[df['SEXO']==0,'SEXO'] = None
   # Substituindo valor 1 por 0
   df.loc[df['SEXO'] == 1, 'SEXO'] = 0
   # Substituindo valor 2 por 1
   df.loc[df['SEXO']==2,'SEXO'] = 1
   # Verificando intervalo de valores - condições:
       # "SEXO >= 0" E "SEXO <= 1"
   verifica_dummy(df, 'SEXO')
   log_output.info('\n\n======\n')
   return df
def passo_grau_instr(passo, df):
   Substituir valores da coluna "GRAU_INSTR"
   * Substituir todos valores **2** por **1**
```

```
* Substituir todos valores **3** por **1**
* Substituir todos valores **4** por **2**
* Substituir todos valores **5** por **2**
* Substituir todos valores **6** por **3**
* Substituir todos valores **7** por **3**
* Substituir todos valores **8** por **4**
* Substituir todos valores **0** por **None**
#### Categorias anteriores:
Valor/Descrição
----/---
1/Não-alfabetizado
2/Pré-escola
3/1° Grau incompleto
4/1° Grau completo
5/2° Grau incompleto
6/2° Grau completo
7/Superior Incompleto
8/Superior Completo
#### Categorias novas
Valor/Descrição
----/---
1/Não-Alfabetizado/Fundamental Incompleto
2/Fundamental Completo/Médio Incompleto
3/Médio Completo/Superior Incompleto
4/Superior completo
[Teste: Checar se existe algum número < 1 ou > 4.
    Se encontrar, retornar erro indicando em qual linha.]
:param passo: Número do passo atual para registro/log
:param df:
:return: retorna dataframe modificado
log_tela.info("### PASSO " + str(passo) + " - GRAU_INSTR")
# Substituindo valor 2 por 1
df.loc[df['GRAU_INSTR'] == 2, 'GRAU_INSTR'] = 1
# Substituindo valor 3 por 1
df.loc[df['GRAU_INSTR'] == 3, 'GRAU_INSTR'] = 1
# Substituindo valor 4 por 2
df.loc[df['GRAU_INSTR'] == 4, 'GRAU_INSTR'] = 2
# Substituindo valor 5 por 2
df.loc[df['GRAU_INSTR'] == 5, 'GRAU_INSTR'] = 2
# Substituindo valor 6 por 3
df.loc[df['GRAU_INSTR'] == 6, 'GRAU_INSTR'] = 3
# Substituindo valor 7 por 3
df.loc[df['GRAU_INSTR'] == 7, 'GRAU_INSTR'] = 3
# Substituindo valor 8 por 4
df.loc[df['GRAU_INSTR'] == 8, 'GRAU_INSTR'] = 4
# Substituindo valor O por None
df.loc[df['GRAU_INSTR'] == 0, 'GRAU_INSTR'] = None
# Verificando intervalo de valores - condições:
```

```
# "GRAU_INSTR >= 1" E "GRAU_INSTR <= 4"
   verifica_range(df, 'GRAU_INSTR', 1, 4)
   log_output.info('\n\n=======\n')
   return df
def passo_ocup(passo, df):
   Substituir valores da coluna "OCUP"
   Substituir todos valores **2** por **1**
   Substituir todos valores **3** por **2**
   Substituir todos valores **5** por **3**
   Substituir todos valores **6** por **5**
   Substituir todos valores **7** por **6**
   Substituir todos valores **8** por **7**
   Substituir todos valores **0** por **None**
   ####Categorias anteriores:
   Valor/Descrição
    ----/---
   1/Ocupado
   2/Ocupado eventualmente
   3/Em licença
   4/Não ocupada
   5/Aposentado/Pensionista
   6/Nunca trabalhou
   7/Dona de casa
   8/Estudante
   ####Categorias novas
   Valor/Descrição
   ----/---
   1/Tem trabalho
   2/Em licença médica
   3/Aposentado / pensionista
   4/Desempregado
   5|Sem ocupação
   6/Dona de casa
   7/Estudante
    [Teste: Checar se existe algum número < 1 ou > 7.
       Se encontrar, retornar erro indicando em qual linha.]
    :param passo: Número do passo atual para registro/log
    :param df:
    :return: retorna dataframe modificado
   log_tela.info("### PASSO " + str(passo) + " - OCUP")
   # Substituindo valor 2 por 1
   df.loc[df['OCUP']==2,'OCUP'] = 1
   # Substituindo valor 3 por 2
   df.loc[df['OCUP']==3,'OCUP'] = 2
   # Substituindo valor 5 por 3
```

```
df.loc[df['OCUP']==5,'OCUP'] = 3
    # Substituindo valor 6 por 5
    df.loc[df['OCUP']==6,'OCUP'] = 5
    # Substituindo valor 7 por 6
    df.loc[df['OCUP']==7,'OCUP'] = 6
    # Substituindo valor 8 por 7
    df.loc[df['OCUP']==8,'OCUP'] = 7
    # Substituindo valor O por None
    df.loc[df['OCUP']==0,'OCUP'] = None
    # Verificando intervalo de valores - condições:
        # "OCUP >= 1" E "OCUP <= 7"
    verifica_range(df, 'OCUP', 1, 7)
    log_output.info('\n\n======\n')
    return df
def passo_setor_ativ(passo, df):
    Substituir valores da coluna "SETOR_ATIV"
    Na coluna "SETOR_ATIV", linha i,
        ler o valor da linha i da coluna "SETOR_ATIV", daí,
        buscar o mesmo valor na coluna "COD" do arquivo setor_ativ-1997.csv.
    Ao achar, retornar o valor da mesma linha, só que da coluna "COD_UNIF"
    ####Categorias anteriores
    > ver arquivo .csv
    ####Categorias novas
    Valor/Descrição
    ----/---
    1/Agrícola
    2/Construção Civil
    3/Indústria
    4/Comércio
    5/Administração Pública
    6/Serviços de Transporte
    7/Outros serviços
    8/Outros
    9/Não se aplica
    [Teste: Checar se existe algum número < 1 ou > 9.
        Se encontrar, retornar erro indicando em qual linha.]
    :param passo: Número do passo atual para registro/log
    :param df:
    :return: retorna dataframe modificado
    log_tela.info("### PASSO " + str(passo) + " - SETOR_ATIV")
    log_output.info('Lendo arquivo de referência externa setor_ativ-1997.csv')
    df_setor = pd.read_csv('auxiliares/setor_ativ-1997.csv', sep=';', decimal=',')
```

```
def setor_aux(row):
        df.loc[df['SETOR_ATIV'] == row['COD'], 'SETOR_ATIV'] = row['COD_UNIF']
    # Esta variável out não é utilizada para nada além de evitar um
    # monte de output que não será utilizado e que é gerado pelo método apply.
    out = df_setor.apply(setor_aux, axis=1)
    # Substituindo valor O por None
    df.loc[df['SETOR_ATIV'] == 0, 'SETOR_ATIV'] = None
    # Verificando intervalo de valores - condições:
        # "SETOR_ATIV >= 1" E "SETOR_ATIV <= 9"
    verifica_range(df, 'SETOR_ATIV', 1, 9)
    log_output.info('\n\n========\n')
    return df
def passo_ren_ind(passo, df, deflator):
    Corrige a renda individual de acordo com o deflator passado na função.
    :param passo: Número do passo atual para registro/log
    :param df: dataframe
    :param deflator: Deflator utilizado para correção da renda.
    :return: sem retorno
    log_tela.info("### PASSO " + str(passo) + " - REN_IND")
    df['REN_IND'] = df['REN_IND'] * deflator
    return df
def passo_cd_renind(passo, df):
    Substituir valores da coluna "CD_RENIND"
    * Substituir todos valores **3** por None
    * Substituir todos valores **2** por **0**
    #### Categorias anteriores
    Valor/Descrição
    ----/---
    1/Tem renda
    2/Não tem renda
    3/Não respondeu
    ####Categorias novas
    Valor/Descrição
    ____/___/____
        /Não tem renda
        |Tem renda
    [Teste: Checar se existe algum número < 0 ou > 1.
```

```
Se encontrar, retornar erro indicando em qual linha.]
    :param passo: Número do passo atual para registro/log
    :param df:
    :return: sem retorno
    log_tela.info("### PASSO " + str(passo) + " - CD_RENIND")
    df.loc[df['CD_RENIND'] == 3, 'CD_RENIND'] = None
    df.loc[df['CD_RENIND'] == 2, 'CD_RENIND'] = 0
    # Verificando intervalo de valores - condições:
        # "CD_RENIND >= 0" E "CD_RENIND <= 1"
    verifica_dummy(df, 'CD_RENIND')
    log_output.info('\n\n========\n')
    return df
def passo_estuda(passo, df):
    Se zona da escola for zero (0) então não estuda (0), senão, estuda (1)
    #############################
             ATENCÃO
    # ESTA FUNÇÃO SÓ DEVE SER #
    # EXECUTADA APÓS A GERAÇÃO#
    # DE TODOS OS ID'S, POIS #
      HÁ UMA DESCONFIANÇA #
      QUANTO À QUALIDADE
            DESTE DADO
    #############################
    * Substituir todos valores **1** por **0**
    * Substituir todos valores **2** por **1**
    * Substituir todos valores **3** por **1**
    * Substituir todos valores **4** por **1**
    #### Categorias anteriores
    Valor/Descrição
    ----/---
    1/Não
    2/Creche/Pré-Escola
    3/1° Grau/2° Grau/3° Graus
    4/Outros
    #### Categorias novas
    Valor/Descrição
    ----/---
    OlNão estuda
    1/Estuda
    [Teste: Checar se existe algum número diferente de 0 ou 1.
        Se encontrar, retornar erro indicando em qual linha.]
    :param passo: Número do passo atual para registro/log
```

```
:param df:
:return: retorna dataframe com campo ESCOLA resolvido
log_tela.info("### PASSO " + str(passo) + " - ESTUDA")
# Substitui 1 por 0
df.loc[df['ESTUDA'] == 1, 'ESTUDA'] = 0
# Substitui 2 por 1
df.loc[df['ESTUDA'] == 2, 'ESTUDA'] = 1
# Substitui 3 por 1
df.loc[df['ESTUDA'] == 3, 'ESTUDA'] = 1
# Substitui 4 por 1
df.loc[df['ESTUDA'] == 4, 'ESTUDA'] = 1
{\it \# Substituindo\ todos\ que\ declararam\ zona\ escola\ diferente\ de\ zero}
    # com campo ESTUDA igual a 1.
df.loc[(df['ZONA_ESC'] != 0)&
       (df['ZONA_ESC'].notnull()), 'ESTUDA'] = 1
verifica_dummy(df, 'ESTUDA')
log_output.info('\n\n=======\n')
return df
```

3.6 Funções referentes da Viagem

Função/Variável	Status
passo_f_viag	ОК
passo_fe_viag	OK
passo_zona_esc	OK
$passo_subzona_esc$	OK
passo_mun_esc	OK
passo_zona_trab1	OK
$passo_subzona_trab1$	OK
$passo_mun_trab1$	OK
$passo_zona_trab2$	OK
$passo_subzona_trab2$	OK
$passo_mun_trab2$	OK
passo_zona_orig	OK
$passo_subzona_orig$	OK
passo_mun_orig	OK
passo_zona_dest	OK
$passo_subzona_dest$	OK
$passo_mun_dest$	OK
passo_serv_pas_orig	OK
$passo_serv_pas_dest$	OK
passo_motivo_orig	OK
$passo_motivo_dest$	OK
passo_modo1	OK
$passo_modo2$	OK
$passo_modo3$	OK
passo_modo4	OK
passo_modo_prin	OK
passo_tipo_est_auto	OK
passo_valor_est_auto	OK
passo_tot_viag	OK

Obs: O passo_tot_viag só deve ser executado após a produção dos ID's e NO's.

```
Checar se existe algum erro na coluna "F_VIAG"
   # ####Categorias
   # Valor/Descrição
   # ----
   # O/Não fez viagem
   # 1|Fez viagem
    [Teste: Checar se existe algum número diferente de 0 ou 1.
       Se encontrar, retornar erro indicando em qual linha.]
    :param passo: Número do passo atual para registro/log
    :param df:
    :return: retorna o dataframe com F_VIAG modificado
   log_tela.info("### PASSO " + str(passo) + " - F_VIAG")
   # Setando F_VIAG=1 para todos os casos
   df['F_VIAG'] = 1
   # Setando F_VIAG=0 se DURACAO==0
   df.loc[df['DURACAO']==0,'F_VIAG'] = 0
   verifica_dummy(df, 'F_VIAG')
   log_output.info('\n\n========\n')
   return df
def passo_fe_viag(passo, df):
   # Nada há que se fazer em relação aos dados da coluna "FE_VIAG"
   :param passo: Número do passo atual para registro/log
    :param df:
    :return: sem retorno
   log_tela.info("### PASSO " + str(passo) + " - FE_VIAG")
   log_output.info('\n\n========\n')
   return df
def passo_zona_esc(passo, df):
   Checar se existe algum erro
   # ####Categorias:
   # > 1 a 389
    [Teste: Checar se existe algum número < 1 ou > 389.
       Se encontrar, retornar erro indicando em qual linha.]
    :param passo: Número do passo atual para registro/log
    :param df:
    :return: Sem retorno
```

```
11 11 11
    log_tela.info("### PASSO " + str(passo) + " - ZONA_ESC")
    # Substituindo valor O por None
    df.loc[df['ZONA_ESC'] == 0, 'ZONA_ESC'] = None
    # Verificando intervalo de valores - condições:
       # "ZONA_ESC >= 1" E "ZONA_ESC <= 389"
    verifica_range(df, 'ZONA_ESC', 1, 389)
    log_output.info('\n\n=======\n')
    return df
def passo_subzona_esc(passo, df):
    Checar se existe algum erro
    # ####Categorias:
    \# > 1 \ a \ 9
    [Teste: Checar se existe algum número < 1 ou > 9.
       Se encontrar, retornar erro indicando em qual linha.]
    :param passo: Número do passo atual para registro/log
    :param df:
    :return: sem retorno
    log_tela.info("### PASSO " + str(passo) + " - SUBZONA_ESC")
    # Substituindo valor O por None
    df.loc[df['SUBZONA_ESC'] == 0, 'SUBZONA_ESC'] = None
    # Verificando intervalo de valores - condições:
        # "SUBZONA_ESC >= 1" E "SUBZONA_ESC <= 9"
    verifica_range(df, 'SUBZONA_ESC', 1, 9)
    log_output.info('\n\n========\n')
    return df
def passo_mun_esc(passo, df):
    Checar se existe algum erro
    # ####Categorias
    # > 1 a 39
    [Teste: Checar se existe algum número < 1 ou > 39.
       Se encontrar, retornar erro indicando em qual linha.]
    :param passo: Número do passo atual para registro/log
    :param df:
    :return: sem retorno
    11 11 11
    log_tela.info("### PASSO " + str(passo) + " - MUN_ESC")
```

```
# Substituindo valor O por None
    df.loc[df['MUN_ESC']==0,'MUN_ESC'] = None
    # Verificando intervalo de valores - condições:
       # "MUN_ESC >= 1" E "MUN_ESC <= 39"
    verifica_range(df, 'MUN_ESC', 1, 39)
    log_output.info('\n\n=======\n')
    return df
def passo_zona_trab1(passo, df):
    Checar se existe algum erro
    # ####Categorias:
    # > 1 a 389
    [Teste: Checar se existe algum número < 1 ou > 389.
       Se encontrar, retornar erro indicando em qual linha.]
    :param passo: Número do passo atual para registro/log
    :param df:
    :return: sem retorno
    log_tela.info("### PASSO " + str(passo) + " - ZONA_TRAB1")
    # Substituindo valor O por None
    df.loc[df['ZONA_TRAB1']==0,'ZONA_TRAB1'] = None
    # Verificando intervalo de valores - condições:
        # "ZONA_TRAB1 >= 1" E "ZONA_TRAB1 <= 389"
    verifica_range(df, 'ZONA_TRAB1', 1, 389)
    log_output.info('\n\n=====
                                         ========\n')
    return df
def passo_subzona_trab1(passo, df):
    Checar se existe algum erro
    # ####Categorias:
    # > 1 a 9
    [Teste: Checar se existe algum número < 1 ou > 9.
       Se encontrar, retornar erro indicando em qual linha.]
    :param passo: Número do passo atual para registro/log
    :param df:
    :return: sem retorno
    log_tela.info("### PASSO " + str(passo) + " - SUBZONA_TRAB1")
    # Substituindo valor O por None
```

```
df.loc[df['SUBZONA_TRAB1']==0, 'SUBZONA_TRAB1'] = None
   # Verificando intervalo de valores - condições:
       # "SUBZONA_TRAB1 >= 1" E "SUBZONA_TRAB1 <= 9"
   verifica_range(df, 'SUBZONA_TRAB1', 1, 9)
   log_output.info('\n\n========\n')
   return df
def passo_mun_trab1(passo, df):
   Checar se existe algum erro
   # ####Categorias
   # > 1 a 39
    [Teste: Checar se existe algum número < 1 ou > 39.
       Se encontrar, retornar erro indicando em qual linha.]
    :param passo: Número do passo atual para registro/log
    :param df:
    :return: sem retorno
   log_tela.info("### PASSO " + str(passo) + " - MUN_TRAB1")
   # Substituindo valor O por None
   df.loc[df['MUN_TRAB1'] == 0, 'MUN_TRAB1'] = None
   # Verificando intervalo de valores - condições:
        # "MUN_TRAB1 >= 1" E "MUN_TRAB1 <= 39"
   verifica_range(df, 'MUN_TRAB1', 1, 39)
   log_output.info('\n\n========\n')
   return df
def passo_zona_trab2(passo, df):
   Checar se existe algum erro
   # ####Categorias:
   # > 1 a 389
    [Teste: Checar se existe algum número < 1 ou > 389.
       Se encontrar, retornar erro indicando em qual linha.]
    :param passo: Número do passo atual para registro/log
    :param df:
    :return: sem retorno
   log_tela.info("### PASSO " + str(passo) + " - ZONA_TRAB2")
   # Substituindo valor O por None
   df.loc[df['ZONA_TRAB2']==0,'ZONA_TRAB2'] = None
```

```
# Verificando intervalo de valores - condições:
        # "ZONA_TRAB2 >= 1" E "ZONA_TRAB2 <= 389"
    verifica_range(df, 'ZONA_TRAB2', 1, 389)
    log_output.info('\n\n=======\n')
    return df
def passo_subzona_trab2(passo, df):
    Checar se existe algum erro
    # ####Categorias:
    \# > 1 \ a \ 9
    [Teste: Checar se existe algum número < 1 ou > 9.
       Se encontrar, retornar erro indicando em qual linha.]
    :param passo: Número do passo atual para registro/log
    :param df:
    :return: sem retorno
    log_tela.info("### PASSO " + str(passo) + " - SUBZONA_TRAB2")
    # Substituindo valor O por None
    df.loc[df['SUBZONA_TRAB2'] == 0, 'SUBZONA_TRAB2'] = None
    # Verificando intervalo de valores - condições:
        # "SUBZONA_TRAB2 >= 1" E "SUBZONA_TRAB2 <= 9"
    verifica_range(df, 'SUBZONA_TRAB2', 1, 9)
    log_output.info('\n\n========\n')
    return df
def passo_mun_trab2(passo, df):
    Checar se existe algum erro
    # ####Categorias
    # > 1 a 39
    [Teste: Checar se existe algum número < 1 ou > 39.
       Se encontrar, retornar erro indicando em qual linha.]
    :param passo: Número do passo atual para registro/log
    :param df:
    :return: sem retorno
    log_tela.info("### PASSO " + str(passo) + " - MUN_TRAB2")
    # Substituindo valor O por None
    df.loc[df['MUN_TRAB2']==0,'MUN_TRAB2'] = None
    # Verificando intervalo de valores - condições:
       # "MUN_TRAB2 >= 1" E "MUN_TRAB2 <= 39"
```

```
verifica_range(df, 'MUN_TRAB2', 1, 39)
   log_output.info('\n\n=======\n')
   return df
def passo_zona_orig(passo, df):
   Checar se existe algum erro
   # ####Categorias:
    # > 1 a 389
    [Teste: Checar se existe algum número < 1 ou > 389.
       Se encontrar, retornar erro indicando em qual linha.]
    :param passo: Número do passo atual para registro/log
    :param df:
    :return: sem retorno
   log_tela.info("### PASSO " + str(passo) + " - ZONA_ORIG")
   # Substituindo valor O por None
   df.loc[df['ZONA_ORIG'] == 0, 'ZONA_ORIG'] = None
   # Verificando intervalo de valores - condições:
       # "ZONA_ORIG >= 1" E "ZONA_ORIG <= 389"
   verifica_range(df, 'ZONA_ORIG', 1, 389)
   log_output.info('\n\n======\n')
   return df
def passo_subzona_orig(passo, df):
   Checar se existe algum erro
   # ####Categorias:
   \# > 1 \ a \ 9
    [Teste: Checar se existe algum número < 1 ou > 9.
       Se encontrar, retornar erro indicando em qual linha.]
    :param passo: Número do passo atual para registro/log
    :param df:
    :return: sem retorno
   log_tela.info("### PASSO " + str(passo) + " - SUBZONA_ORIG")
   # Substituindo valor O por None
   df.loc[df['SUBZONA_ORIG'] == 0, 'SUBZONA_ORIG'] = None
   # Verificando intervalo de valores - condições:
       # "SUBZONA_ORIG >= 1" E "SUBZONA_ORIG <= 9"
   verifica_range(df, 'SUBZONA_ORIG', 1, 9)
   log_output.info('\n\n========\n')
```

return df

```
def passo_mun_orig(passo, df):
   Checar se existe algum erro
   # ####Categorias
   # > 1 a 39
    [Teste: Checar se existe algum número < 1 ou > 39.
       Se encontrar, retornar erro indicando em qual linha.]
    :param passo: Número do passo atual para registro/log
    :param df:
    :return: sem retorno
   log_tela.info("### PASSO " + str(passo) + " - MUN_ORIG")
   # Substituindo valor O por None
   df.loc[df['MUN_ORIG'] == 0, 'MUN_ORIG'] = None
   # Verificando intervalo de valores - condições:
       # "MUN_ORIG >= 1" E "MUN_ORIG <= 39"
   verifica_range(df, 'MUN_ORIG', 1, 39)
   log_output.info('\n\n========\n')
   return df
def passo_zona_dest(passo, df):
   Checar se existe algum erro
   # ####Categorias:
    # > 1 a 389
    [Teste: Checar se existe algum número < 1 ou > 389.
       Se encontrar, retornar erro indicando em qual linha.]
    :param passo: Número do passo atual para registro/log
    :param df:
   :return: sem retorno
   log_tela.info("### PASSO " + str(passo) + " - ZONA_DEST")
   # Substituindo valor O por None
   df.loc[df['ZONA_DEST'] == 0, 'ZONA_DEST'] = None
   # Verificando intervalo de valores - condições:
       # "ZONA_DEST >= 1" E "ZONA_DEST <= 389"
   verifica_range(df, 'ZONA_DEST', 1, 389)
   log_output.info('\n\n======\n')
   return df
```

```
def passo_subzona_dest(passo, df):
    Checar se existe algum erro
    # ####Categorias:
    \# > 1 \ a \ 9
    [Teste: Checar se existe algum número < 1 ou > 9.
       Se encontrar, retornar erro indicando em qual linha.]
    :param passo: Número do passo atual para registro/log
    :param df:
    :return: sem retorno
    log_tela.info("### PASSO " + str(passo) + " - SUBZONA_DEST")
    # Substituindo valor O por None
    df.loc[df['SUBZONA_DEST'] == 0, 'SUBZONA_DEST'] = None
    # Verificando intervalo de valores - condições:
        # "SUBZONA_DEST >= 1" E "SUBZONA_DEST <= 9"
    verifica_range(df, 'SUBZONA_DEST', 1, 9)
    log_output.info('\n\n========\n')
    return df
def passo_mun_dest(passo, df):
    Checar se existe algum erro
    # ####Categorias
    # > 1 a 39
    [Teste: Checar se existe algum número < 1 ou > 39.
       Se encontrar, retornar erro indicando em qual linha.]
    :param passo: Número do passo atual para registro/log
    :param df:
    :return: sem retorno
    log_tela.info("### PASSO " + str(passo) + " - MUN_DEST")
    # Substituindo valor O por None
    df.loc[df['MUN_DEST'] == 0, 'MUN_DEST'] = None
    # Verificando intervalo de valores - condições:
        # "MUN_DEST >= 1" E "MUN_DEST <= 39"
    verifica_range(df, 'MUN_DEST', 1, 39)
    log_output.info('\n\n========\n')
    return df
def passo_serv_pas_orig(passo, df):
```

```
Substituir **0** por None
   Substituir **2** por **0**
   ####Categorias antigas
   Valor/Descrição
   ----/---
   O/Não Respondido
   1|Sim
   2/Não
   ####Categorias novas
   Valor/Descrição
   ----/---
   0/Não
   1/Sim
   :param passo: Número do passo atual para registro/log
   :param df:
    :return: sem retorno
   log_tela.info("### PASSO " + str(passo) + " - SERV_PAS_ORIG")
   df.loc[df['SERV_PAS_ORIG'] == 0, 'SERV_PAS_ORIG'] = None
   df.loc[df['SERV_PAS_ORIG'] == 2, 'SERV_PAS_ORIG'] = 0
   verifica_dummy(df, 'SERV_PAS_ORIG')
   log_output.info('\n\n======\n')
   return df
def passo_serv_pas_dest(passo, df):
   Substituir **0** por None
   Substituir **2** por **0**
   ####Categorias antigas
   Valor/Descrição
   ----/----
   O/Não Respondido
   1/Sim
   2/Não
   ####Categorias novas
   Valor/Descrição
   ----/---
   0/Não
   1/Sim
   :param passo: Número do passo atual para registro/log
   :param df:
   :return: sem retorno
    n n n
```

```
log_tela.info("### PASSO " + str(passo) + " - SERV_PAS_DEST")
    df.loc[df['SERV_PAS_DEST'] == 0, 'SERV_PAS_DEST'] = None
    df.loc[df['SERV_PAS_DEST'] == 2, 'SERV_PAS_DEST'] = 0
    verifica_dummy(df, 'SERV_PAS_DEST')
    log_output.info('\n\n========\n')
    return df
def passo_motivo_orig(passo, df):
    * Substituir todos valores **0** por **None**
    #### Categorias anteriores
    Valor/Descrição
    ----/---
    1/Trabalho/Indústria
    2/Trabalho/Comércio
    3/Trabalho/Serviços
    4/Escola/Educação
    5/Compras
    6/Médico/Dentista/Saúde
    7/Recreação/Visitas
    8/Residência
    9/Outros
    #### Categorias novas
    Valor/Descrição
    ----/---
    1/Trabalho/Indústria
    2/Trabalho/Comércio
    3/Trabalho/Serviços
    4/Educação
    5/Compras
    6/Saúde
    7/Lazer
    8/Residência
    9/Outros
    [Teste: Checar se existe algum número < 1 ou > 9.
        Se encontrar, retornar erro indicando em qual linha.]
    :param passo: Número do passo atual para registro/log
    :param df:
    :return: dataframe modificado
    log_tela.info("### PASSO " + str(passo) + " - MOTIVO_ORIG")
    # Substituindo valor O por None
    df.loc[df['MOTIVO_ORIG'] == 0, 'MOTIVO_ORIG'] = None
    # Verificando intervalo de valores - condições:
        # "MOTIVO_ORIG >= 1" E "MOTIVO_ORIG <= 9"
```

```
verifica_range(df, 'MOTIVO_ORIG', 1, 9)
   log_output.info('\n\n=======\n')
   return df
def passo_motivo_dest(passo, df):
   * Substituir todos valores **0** por **None**
   #### Categorias anteriores
   Valor/Descrição
   ----/---
   1/Trabalho/Indústria
   2/Trabalho/Comércio
   3/Trabalho/Serviços
   4/Escola/Educação
   5/Compras
   6/Médico/Dentista/Saúde
   7/Recreação/Visitas
   8/Residência
   9/Outros
   #### Categorias novas
   Valor/Descrição
   ----/---
   1/Trabalho/Indústria
   2/Trabalho/Comércio
   3/Trabalho/Serviços
   4/Educação
   5/Compras
   6/Saúde
   7/Lazer
   8/Residência
   9/Outros
    [Teste: Checar se existe algum número < 1 ou > 9.
       Se encontrar, retornar erro indicando em qual linha.]
    :param passo: Número do passo atual para registro/log
    :param df:
   :return: dataframe modificado
   log_tela.info("### PASSO " + str(passo) + " - MOTIVO_DEST")
   # Substituindo valor O por None
   df.loc[df['MOTIVO_DEST'] == 0, 'MOTIVO_DEST'] = None
   # Verificando intervalo de valores - condições:
       # "MOTIVO_DEST >= 1" E "MOTIVO_DEST <= 9"
   verifica_range(df, 'MOTIVO_DEST',1, 9)
   log_output.info('\n\n======\n')
   return df
```

```
def passo_modo1(passo, df):
    Substituir valores da coluna "MODO1"
    * Substituir todos valores **3** por **2**
    * Substituir todos valores **4** por **3**
    * Substituir todos valores **5** por **4**
    * Substituir todos valores **6** por **5**
    * Substituir todos valores **7** por **6**
    * Substituir todos valores **8** por **7**
    * Substituir todos valores **9** por **8**
    * Substituir todos valores **10** por **9**
    * Substituir todos valores **11** por **10**
    * Substituir todos valores **12** por **11**
    * Substituir todos valores **13** por **12**
    * Substituir todos valores **0** por **None**
    #### Categorias anteriores
    Valor/Descrição
    ----/---
    1/\hat{O}nibus
    2/Ônibus Fretado
    3/Transporte Escolar
    4/Dirigindo Automóvel
    5/Passageiro de Automóvel
    6/Táxi
    7/Lotação/Perua
    8|Metrô
    9|Trem
    10/Moto
    11/Bicicleta
    12/A Pé
    13/Outros
    #### Categorias novas
    Valor/Descrição
    ----/----
    1/Onibus
    2/Ônibus Escolar / Empresa
    3/Dirigindo Automóvel
    4/Passageiro de Automóvel
    5/Táxi
    6/Lotação / Perua / Van / Microônibus
    7/Metrô
    8/Trem
    9/Moto
    10/Bicicleta
    11 | A Pé
    12/Outros
    [Teste: Checar se existe algum número < 1 ou > 12.
        Se encontrar, retornar erro indicando em qual linha.]
    :param passo: Número do passo atual para registro/log
```

```
:param df:
    :return: sem retorno
    log_tela.info("### PASSO " + str(passo) + " - MODO1")
    df.loc[df['MODO1']==3,'MODO1'] = 2
    df.loc[df['MODO1']==4,'MODO1'] = 3
    df.loc[df['MODO1'] == 5,'MODO1'] = 4
    df.loc[df['MODO1']==6,'MODO1'] = 5
    df.loc[df['MODO1']==7,'MODO1'] = 6
    df.loc[df['MODO1']==8,'MODO1'] = 7
    df.loc[df['MODO1']==9,'MODO1'] = 8
    df.loc[df['MODO1']==10,'MODO1'] = 9
    df.loc[df['MODO1']==11,'MODO1'] = 10
    df.loc[df['MODO1']==12,'MODO1'] = 11
    df.loc[df['MODO1']==13,'MODO1'] = 12
    df.loc[df['MODO1']==0,'MODO1'] = None
    # Verificando intervalo de valores - condições:
        # "MODO1 >= 1" E "MODO1 <= 12"
    verifica_range(df, 'MODO1', 1, 12)
    log_output.info('\n\n========\n')
    return df
def passo_modo2(passo, df):
    Substituir valores da coluna "MODO2"
    * Substituir todos valores **3** por **2**
    * Substituir todos valores **4** por **3**
    * Substituir todos valores **5** por **4**
    * Substituir todos valores **6** por **5**
    * Substituir todos valores **7** por **6**
    * Substituir todos valores **8** por **7**
    * Substituir todos valores **9** por **8**
    * Substituir todos valores **10** por **9**
    * Substituir todos valores **11** por **10**
    * Substituir todos valores **12** por **11**
    * Substituir todos valores **13** por **12**
    * Substituir todos valores **0** por **None**
    #### Categorias anteriores
    Valor/Descrição
    ----/---
    1/Onibus
    2/Ônibus Fretado
    3/Transporte Escolar
    4/Dirigindo Automóvel
    5/Passageiro de Automóvel
    6/Táxi
    7/Lotação/Perua
    8/Metrô
```

```
9|Trem
   10/Moto
   11/Bicicleta
   12/A Pé
   13/Outros
   #### Categorias novas
   Valor/Descrição
   ----/---
   1/Ônibus
   2/Ônibus Escolar / Empresa
   3/Dirigindo Automóvel
   4/Passageiro de Automóvel
   5/Táxi
   6/Lotação / Perua / Van / Microônibus
   7/Metrô
   8/Trem
   9/Moto
   10/Bicicleta
   11/A Pé
   12/Outros
   [Teste: Checar se existe algum número < 1 ou > 12.
       Se encontrar, retornar erro indicando em qual linha.]
    :param passo: Número do passo atual para registro/log
    :param df:
    :return: sem retorno
   log_tela.info("### PASSO " + str(passo) + " - MODO3")
   df.loc[df['MODO2']==3,'MODO2'] = 2
   df.loc[df['MODO2']==4,'MODO2'] = 3
   df.loc[df['MODO2']==5,'MODO2'] = 4
   df.loc[df['MODO2']==6,'MODO2'] = 5
   df.loc[df['MODO2']==7,'MODO2'] = 6
   df.loc[df['MODO2'] == 8, 'MODO2'] = 7
   df.loc[df['MODO2']==9,'MODO2'] = 8
   df.loc[df['MODO2']==10,'MODO2'] = 9
   df.loc[df['MODO2']==11,'MODO2'] = 10
   df.loc[df['MODO2']==12,'MODO2'] = 11
   df.loc[df['MODO2']==13,'MODO2'] = 12
   df.loc[df['MODO2']==0,'MODO2'] = None
   # Verificando intervalo de valores - condições:
        # "MODO2 >= 1" E "MODO2 <= 12"
   verifica_range(df, 'MODO2', 1, 12)
   log_output.info('\n\n=======\n')
   return df
def passo_modo3(passo, df):
   Substituir valores da coluna "MODO3"
```

```
* Substituir todos valores **3** por **2**
* Substituir todos valores **4** por **3**
* Substituir todos valores **5** por **4**
* Substituir todos valores **6** por **5**
* Substituir todos valores **7** por **6**
* Substituir todos valores **8** por **7**
* Substituir todos valores **9** por **8**
* Substituir todos valores **10** por **9**
* Substituir todos valores **11** por **10**
* Substituir todos valores **12** por **11**
* Substituir todos valores **13** por **12**
* Substituir todos valores **0** por **None**
#### Categorias anteriores
Valor/Descrição
----/---
1/Onibus
2/Onibus Fretado
3/Transporte Escolar
4/Dirigindo Automóvel
5/Passageiro de Automóvel
6/Táxi
7/Lotação/Perua
8|Metrô
9/Trem
10/Moto
11/Bicicleta
12/A Pé
13/Outros
#### Categorias novas
Valor/Descrição
----/---
1/Onibus
2/Onibus Escolar / Empresa
3/Dirigindo Automóvel
4/Passageiro de Automóvel
5/Táxi
6/Lotação / Perua / Van / Microônibus
7/Metrô
8/Trem
9/Moto
10/Bicicleta
11 | A Pé
12/Outros
[Teste: Checar se existe algum número < 1 ou > 12.
    Se encontrar, retornar erro indicando em qual linha.]
:param passo: Número do passo atual para registro/log
:param df:
:return: sem retorno
11 11 11
log_tela.info("### PASSO " + str(passo) + " - MODO3")
```

```
df.loc[df['MODO3']==3,'MODO3'] = 2
   df.loc[df['MODO3'] == 4,'MODO3'] = 3
   df.loc[df['MODO3']==5,'MODO3'] = 4
   df.loc[df['MODO3']==6,'MODO3'] = 5
   df.loc[df['MODO3']==7,'MODO3'] = 6
   df.loc[df['MODO3'] == 8,'MODO3'] = 7
   df.loc[df['MODO3']==9,'MODO3'] = 8
   df.loc[df['MODO3']==10,'MODO3'] = 9
   df.loc[df['MODO3']==11,'MODO3'] = 10
   df.loc[df['MODO3']==12,'MODO3'] = 11
   df.loc[df['MODO3']==13,'MODO3'] = 12
   df.loc[df['MODO3']==0,'MODO3'] = None
   # Verificando intervalo de valores - condições:
        # "MODO3 >= 1" E "MODO3 <= 12"
   verifica_range(df, 'MODO3', 1, 12)
   log_output.info('\n\n=======\n')
   return df
def passo_modo4(passo, df):
   Substituir valores da coluna "MODO4"
   * Substituir todos valores **3** por **2**
   * Substituir todos valores **4** por **3**
   * Substituir todos valores **5** por **4**
   * Substituir todos valores **6** por **5**
   * Substituir todos valores **7** por **6**
   * Substituir todos valores **8** por **7**
   * Substituir todos valores **9** por **8**
   * Substituir todos valores **10** por **9**
   * Substituir todos valores **11** por **10**
   * Substituir todos valores **12** por **11**
   * Substituir todos valores **13** por **12**
    * Substituir todos valores **0** por **None**
   #### Categorias anteriores
   Valor/Descrição
    ----/---
   1/Onibus
   2/Ônibus Fretado
   3/Transporte Escolar
   4/Dirigindo Automóvel
   5/Passageiro de Automóvel
   6/Táxi
   7/Lotação/Perua
   8|Metrô
   9/Trem
   10/Moto
   11/Bicicleta
   12/A Pé
```

```
13/Outros
    #### Categorias novas
    Valor/Descrição
    ----/---
    1/Onibus
    2/Onibus Escolar / Empresa
    3/Dirigindo Automóvel
    4/Passageiro de Automóvel
    5/Táxi
    6/Lotação / Perua / Van / Microônibus
    7/Metrô
    81Trem
    9/Moto
    10/Bicicleta
    11 | A Pé
    12/Outros
    [Teste: Checar se existe algum número < 1 ou > 12.
        Se encontrar, retornar erro indicando em qual linha.]
    :param passo: Número do passo atual para registro/log
    :param df:
    :return: sem retorno
    11 11 11
    log_tela.info("### PASSO " + str(passo) + " - MODO4")
    df.loc[df['MODO4']==3,'MODO4'] = 2
    df.loc[df['MODO4']==4,'MODO4'] = 3
    df.loc[df['MODO4']==5,'MODO4'] = 4
    df.loc[df['MODO4']==6,'MODO4'] = 5
    df.loc[df['MODO4'] == 7,'MODO4'] = 6
    df.loc[df['MODO4'] == 8,'MODO4'] = 7
    df.loc[df['MODO4']==9,'MODO4'] = 8
    df.loc[df['MODO4']==10,'MODO4'] = 9
    df.loc[df['MODO4']==11,'MODO4'] = 10
    df.loc[df['MODO4']==12,'MODO4'] = 11
    df.loc[df['MODO4']==13,'MODO4'] = 12
    df.loc[df['MODO4']==0,'MODO4'] = None
    # Verificando intervalo de valores - condições:
        # "MODO4 >= 1" E "MODO4 <= 12"
    verifica_range(df, 'MODO4', 1, 12)
    log_output.info('\n\n=======\n')
    return df
def passo_modo_prin(passo, df):
    Substituir valores da coluna "MODO_PRIN"
    * Substituir todos valores **3** por **2**
    * Substituir todos valores **4** por **3**
    * Substituir todos valores **5** por **4**
```

```
* Substituir todos valores **6** por **5**
* Substituir todos valores **7** por **6**
* Substituir todos valores **8** por **7**
* Substituir todos valores **9** por **8**
* Substituir todos valores **10** por **9**
* Substituir todos valores **11** por **10**
* Substituir todos valores **12** por **11**
* Substituir todos valores **13** por **12**
* Substituir todos valores **0** por **None**
#### Categorias anteriores
Valor/Descrição
----/---
1/Onibus
2/Ônibus Fretado
3/Transporte Escolar
4/Dirigindo Automóvel
5/Passageiro de Automóvel
6/Táxi
7/Lotação/Perua
8/Metrô
9/Trem
10/Moto
11/Bicicleta
12/A Pé
13/Outros
#### Categorias novas
Valor/Descrição
----/---
1/Onibus
2/\hat{O}nibus Escolar / Empresa
3/Dirigindo Automóvel
4/Passageiro de Automóvel
5/Táxi
6/Lotação / Perua / Van / Microônibus
7/Metrô
8/Trem
9/Moto
10/Bicicleta
11/A Pé
12/Outros
[Teste: Checar se existe algum número < 1 ou > 12.
    Se encontrar, retornar erro indicando em qual linha.]
:param passo: Número do passo atual para registro/log
:param df:
:return: sem retorno
log_tela.info("### PASSO " + str(passo) + " - MODO_PRIN")
df.loc[df['MODO_PRIN'] == 3, 'MODO_PRIN'] = 2
df.loc[df['MODO_PRIN'] == 4, 'MODO_PRIN'] = 3
df.loc[df['MODO_PRIN'] == 5, 'MODO_PRIN'] = 4
```

```
df.loc[df['MODO_PRIN'] == 6, 'MODO_PRIN'] = 5
    df.loc[df['MODO_PRIN'] == 7, 'MODO_PRIN'] = 6
    df.loc[df['MODO_PRIN'] == 8, 'MODO_PRIN'] = 7
    df.loc[df['MODO_PRIN'] == 9, 'MODO_PRIN'] = 8
    df.loc[df['MODO_PRIN'] == 10, 'MODO_PRIN'] = 9
    df.loc[df['MODO_PRIN'] == 11, 'MODO_PRIN'] = 10
    df.loc[df['MODO_PRIN'] == 12, 'MODO_PRIN'] = 11
    df.loc[df['MODO_PRIN']==13,'MODO_PRIN'] = 12
    df.loc[df['MODO_PRIN'] == 0, 'MODO_PRIN'] = None
    # Verificando intervalo de valores - condições:
        # "MODO_PRIN >= 1" E "MODO_PRIN <= 12"
    verifica_range(df, 'MODO_PRIN', 1, 12)
    log_output.info('\n\n========\n')
    return df
def passo_tipo_viag(passo, df):
    * Substituir os valores **0** por **None**
    # ####Categorias novas
    # Valor/Descrição
    # ----
    # 1/Coletivo
    # 2/Individual
    # 3/A pé
    [Teste: Checar se existe algum número < 1 ou > 3.
        Se encontrar, retornar erro indicando em qual linha.]
    :param passo: Número do passo atual para registro/log
    :param df:
    :return: sem retorno
    :param passo: Número do passo atual para registro/log
    :param df:
    :return: sem retorno
    log_tela.info("### PASSO " + str(passo) + " - TIPO_VIAG")
    # Substituindo valor O por None
    df.loc[df['TIPO_VIAG'] == 0, 'TIPO_VIAG'] = None
    # Verificando intervalo de valores - condições:
        # "MODO_PRIN >= 1" E "MODO_PRIN <= 3"
    verifica_range(df, 'TIPO_VIAG', 1, 3)
    log_output.info('\n\n========\n')
    return df
def passo_tipo_est_auto(passo, df):
    11 11 11
    Nada a fazer, essa informação não existe em 1997
```

```
# Valor/Descrição
   # ----
   # O/Não Respondeu
   # 1/Não Estacionou
   # 2/Estacionamento Particular (Avulso / Mensal)
   # 3/Estacionamento Próprio
   # 4/Estacionamento Patrocinado
   # 5/Rua (meio fio / zona azul / zona marrom / parquímetro)
   [Teste: Checar se existe algum número < 0 ou > 5.
       Se encontrar, retornar erro indicando em qual linha.]
   :param passo: Número do passo atual para registro/log
   :return: retorna dataframe modificado
   log_tela.info("### PASSO " + str(passo) + " - TIPO_EST_AUTO")
   df['TIPO_EST_AUTO'] = None
   log_output.info('\n\n========\n')
   return df
def passo_valor_est_auto(passo, df, deflator):
   Nada há que se fazer em relação à coluna "VALOR_EST_AUTO".
   Não há dados de 1997, coluna permanecerá vazia
   :param passo: Número do passo atual para registro/log
   :param df:
   :return: sem retorno
   log_tela.info("### PASSO " + str(passo) + " - VALOR_EST_AUTO")
   df['VALOR_EST_AUTO'] = None
   log_output.info('\n\n========\n')
   return df
def passo_tot_viag(passo, df):
   ATENÇÃO
   # ESTA FUNÇÃO SÓ DEVE SER #
   # EXECUTADA APÓS A GERAÇÃO#
   # DE TODOS OS ID'S, POIS #
      HÁ UMA DESCONFIANÇA #
     QUANTO À QUALIDADE
           DESTE DADO
   ##############################
```

```
Calcula e confere o campo TOT_VIAG,
   baseado no maior valor de NO_VIAG para cada pessoa
:param passo: Número do passo atual para registro/log
:param df:
:return: retorna o dataframe com o "TOT_VIAG" corrigido
log_tela.info("### PASSO " + str(passo) + " - TOT_VIAG")
log_tela.warning('\n\n############################# \n' +
                'Este passo DEVE ser executado apenas após a \n' +
                'execução dos passos que geram os novos IDs\n' +
                '####################################\n' )
# 'Calculando' o máximo de viagens para cada indivíduo
    Agrupa por ID_PESS e encontra o máximo para NO_VIAG.
    O resultado é um objeto do tipo "Series" cujo index é
    ID_PESS e a variável é NO_VIAG. Em seguida transforma
    esse objeto num DataFrame e depois renomeia a coluna
    NO_VIAG para MAX_VIAG.
df_max = pd.DataFrame(
       df.groupby('ID_PESS')['NO_VIAG'].max()).rename(
           columns={'NO_VIAG': 'MAX_VIAG'})
# Criando um novo dataframe auxiliar apenas com ID_PESS, apenas para ficar mais leve
# O passo sequinte é atribuir o MAX_VIAG à coluna TOT_VIAG
# do dataframe df, linkando por ID_PESS. Isso é feito usando o
# método 'merge' da biblioteca pandas.
df['TOT_VIAG'] = pd.merge(df, df_max, how='left', left_on='ID_PESS',
                            right_index=True)['MAX_VIAG']
log_output.info('TOT_VIAG:\n\n' +
                            Situação final dos dados: \n' +
                       str(df['TOT_VIAG'].describe()) + '\n' +
                            TOT_VIAG: Situação final dos dados: \n' +
                       str(df['TOT_VIAG'].value_counts()))
# Agora uma função que irá verificar se para todo "ID_PESS" o "TOT_VIAG"
    # é iqual ao 'NO_VIAG' máximo.
def verifica_no_viag_tot_viag(row):
   if row['NO_VIAG'] != row['TOT_VIAG']:
       log_output.warning('TOT_VIAG: Erro encontrado na linha '
                                 + str(row) + ':\n'
                                 + ' => ' + row
df.loc[:, ['ID_PESS', 'NO_VIAG', 'TOT_VIAG']]\
    .groupby('ID_PESS')\
    .agg({'NO_VIAG': 'max', 'ID_PESS': 'max', 'TOT_VIAG': 'max'})\
    .apply(verifica_no_viag_tot_viag, axis=1)
log_output.info('\n\n========\n')
return df
```

3.7 Funções que geram os "NO"s e os "ID"s

Função/Variável	Status
gera_nos_e_ids	Verificar NO VIAG

```
def gera_nos_e_ids(passo, df):
```

Esta função gera todos os IDs e todos os NOs das variáveis: DOM (domicílio), FAM (família), PESS (pessoa) e VIAG (viagem) A ordem de geração é:

 $\it NO_DOM$, $\it ID_DOM$, $\it NO_FAM$, $\it ID_FAM$, $\it NO_PESS$, $\it ID_PESS$, $\it NO_VIAG$, $\it ID_VIAG$ Esta ordem é fixa pois cada uma dessas variáveis depende da geração da variável anterior.

Os NOs são gerados como se fossem subíndices.

No caso dos domicílios, eles são contabilizados dentro de cada zona. Assim, cada novo domicílio que aparece na listagem recebe um número que representa sua posição na sequência de domicílios dentro da zona na qual ele está contido.

As famílias seguem o mesmo raciocínio, com relação ao domicílio, as pessoas com relação às famílias e as viagens com relação às pessoas.

Deve-se apenas tomar cuidado com as viagens, pois existem pessoas que não realizaram viagens. Neste caso, estes registros devem contabilizar o NO_VIAG como zero, e não como 1. Para contemplar estes casos, vamos utilizar a variável F_VIAG , que representa quando há ou não viagem naquele registro (F_VIAG ==1 tem viagem, F_VIAG ==0 não tem viagem). Assim, o que precisamos fazer para calcular o NO_VIAG é agrupar os registros por pessoa (ID_PESS) e, dentro de cada agrupamento, somar o valor de F_VIAG registro a registro (linha por linha) cumulativamente. No final do processo, atribui-se zero a NO_VIAG quando F_VIAG for igual a zero.

def gera_id_dom(row):

```
"""

Gera o ID_DOM baseado no 'ANO', na 'ZONA_DOM' e no 'NO_DOM'

O argumento passado é a "linha".

Uso:

df['ID_DOM'] = df.apply(gera_ID_DOM, axis=1)

Retorna: ID_DOM da respectiva linha
"""

# Formatando o ano para strign
ano = str(row['ANO'])

# Formatando a zona para ficar como string com 3 caracteres
zona = str('%03d', "row['ZONA_DOM'])
```

```
# Formatando no_dom para ficar como string com 4 caracteres
    no\_dom = str('\%04d' \% row['NO\_DOM'])
    # Retornando o número inteiro correspondente à string
        # concatenada de ano + zona + no_dom
    return ano + zona + no_dom
def gera_id_fam(row):
    Gera o ID_FAM baseado no 'ID_DOM' e no 'NO_FAM'
    O argumento passado é a "linha".
        Uso:
        df['ID\_FAM'] = df.apply(qera\_ID\_FAM, axis=1)
    Retorna: ID_FAM da respectiva linha
    # Formatando id_dom como string
    id_dom = str(row['ID_DOM'])
    # Formatando no_fam como string para ficar com 2 caracteres
   no_fam = str('%02d' % row['NO_FAM'])
    # Retornando o número inteiro correspondente à string
        # concatenada de ID_DOM com NO_FAM
    return id_dom + no_fam
def gera_id_pess(row):
    Gera o ID_PESS baseado no 'ID_FAM' e no 'NO_PESS'
    O argumento passado é a "linha".
        df['ID_PESS'] = df.apply(gera_ID_PESS, axis=1)
    Retorna: ID_PESS da respectiva linha
    # Formatando id_fam como string
    id_fam = str(row['ID_FAM'])
    # Formatando no_pess como string para ficar com 2 caracteres
   no_pess = str('%02d' % row['NO_PESS'])
    # Retornando o número inteiro correspondente à string
        # concatenada de ID_FAM com NO_PESS
    return id_fam + no_pess
def gera_id_viag(row):
    11 11 11
    Gera o ID_VIAG baseado no 'ID_PESS' e no 'NO_VIAG'
    O argumento passado é a "linha".
        df['ID\_VIAG'] = df.apply(gera\_ID\_VIAG, axis=1)
    Retorna ID_VIAG da respectiva linha
    # Formatando id_pess como string
    id_pess = str(row['ID_PESS'])
```

```
# Formatando no_viag como string para ficar com 2 caracteres
   no_viag = str('%02d' % row['NO_VIAG'])
    # Retornando o número inteiro correspondente à string
        # concatenada de ID_PESS com NO_VIAG
   return id_pess + no_viag
#gera NO_DOM
log_tela.info("Gerando NO_DOM")
df['NO_DOM'] = df.groupby('ZONA_DOM', sort=False)['F_DOM'].cumsum()
log_tela.info("NO_DOM gerado")
log_tela.info("Gerando ID_DOM")
#qera ID_DOM
df['ID_DOM'] = df.apply(gera_id_dom, axis=1)
log_tela.info("ID_DOM gerado")
#gera NO_FAM
log_tela.info("Gerando NO_FAM")
df['NO_FAM'] = df.groupby('ID_DOM', sort=False)['F_FAM'].cumsum()
log_tela.info("NO_FAM gerado")
log_tela.info("Gerando ID_FAM")
#gera ID_FAM
df['ID_FAM'] = df.apply(gera_id_fam, axis=1)
log_tela.info("ID_FAM gerado")
#gera NO_PESS
log_tela.info("Gerando NO_PESS")
df['NO_PESS'] = df.groupby('ID_FAM', sort=False)['F_PESS'].cumsum()
log_tela.info("NO_PESS gerado")
log_tela.info("Gerando ID_PESS")
#qera ID_PESS
df['ID_PESS'] = df.apply(gera_id_pess, axis=1)
log_tela.info("ID_PESS gerado")
#gera NO_VIAG
log_tela.info("Gerando NO_VIAG")
#df['NO_VIAG'] = 1
df['NO_VIAG'] = df.groupby('ID_PESS', sort=False)['F_VIAG'].cumsum()
# Verificando se FE_VIAG == 0 e zerando NO_VIAG nesse caso
df.loc[df['FE_VIAG'] == 0, 'NO_VIAG'] = 0
log_tela.info("NO_VIAG gerado")
log_tela.info("Gerando ID_VIAG")
#gera ID_VIAG
df['ID_VIAG'] = df.apply(gera_id_viag, axis=1)
log_tela.info("ID_VIAG gerado")
return df
```

3.8 Função relativa à entrevista

Função/Variável	Status
passo_cd_entre	OK

Obs: o passo_cd_entre deve ser executado após o passo_tot_viag.

```
In [ ]: log_tela.info('Definindo função relativa à entrevista')
       log_output.info('\n\n========\n')
       def passo_cd_entre(passo, df):
           ############################
                   ATENÇÃO
           # ESTA FUNÇÃO SÓ DEVE SER #
           # EXECUTADA APÓS A GERAÇÃO#
                  DO TOT_VIAG
           #############################
           Substituir valores da coluna "CD_ENTRE"
           Todas viagens são consideradas "completas", segundo informações do Metrô
           * sem viagem: se TOT_VIAG == 0
           * com viagem: se TOT_VIAG != 0
           # ####Categorias novas
           # | Valor | Descrição |
           # / ----- / ----- /
           # | 0 | Completa sem viagem |
           # | 1 | Completa com viagem |
           [Teste: Checar se existe algum número diferente de 0 ou 1.
               Se encontrar, retornar erro indicando em qual linha.]
           :param passo: Número do passo atual para registro/log
           :param df:
           :return:
           log_tela.info("### PASSO " + str(passo) + " - CD_ENTRE")
           log_tela.warning('\n\n########################### \n' +
                           'Este passo DEVE ser executado apenas após a \n' +
                           'execução do passo que geram o TOT_VIAG.\n' +
                           '#################################\n' )
           # Definindo 'CD_ENTRE' baseado no valor de 'TOT_VIAG'
           df.loc[df['TOT_VIAG'] == 0, 'CD_ENTRE'] = 0
           df.loc[df['TOT_VIAG'] != 0, 'CD_ENTRE'] = 1
           verifica_dummy(df, 'CD_ENTRE')
           log_output.info('\n\n========\n')
           return df
```

```
In []: def passo_correcoes(passo, df):
    log_tela.info("### PASSO " + str(passo) + " - Correções")

log_tela.info("Corrigindo 'SERV_PAS' caso TOT_VIAG seja nulo.")
    df.loc[df['TOT_VIAG'] == 0, 'SERV_PAS_ORIG'] = 0
    df.loc[df['TOT_VIAG'] == 0, 'SERV_PAS_DEST'] = 0

return df
```

4 Definindo a função principal (main)

Esta função vai ler os arquivos (csv) necessários e, então, irá efetuar cada passo, chamando as respectivas funções que foram definidas acima. Ao final, esta função irá salvar o resultado das transformações realizadas num arquivo csv.

```
In [ ]: def main():
           start_time = time.time()
           log_tela.info("Horário de início da execução: %s" %
                                   time.strftime("%H:%M", time.localtime(start_time)))
           # ----
           log_tela.info('Lendo arquivos CSV')
           log_output.info('Lendo CSV da base original da OD.')
           od = pd.read_csv('bases/OD_1997.csv', sep=';', decimal=',')
           deflator = 1.94136464
           log_output.info('Deflator a ser utilizado para correção monetária: ' +
                           str(deflator))
           # Filtrando dataframe para pegar apenas uma amostra
           \#od = od[:1000].copy()
           log_output.info('\n\n========\n')
           log_tela.info('Pré-Processamento.')
           od = pre_processamento(od)
           log_tela.info('Imprimindo a lista de variáveis do dataframe da OD.')
           log_tela.debug(od.columns.tolist())
           #Contador de 'PASSO'
           passo = 1
           # ----
           # ##Passo: "ANO"
           od = passo_ano(passo, od)
           passo += 1
           # ##Passo: "DIA_SEM"
           od = passo_dia_sem(passo, od)
           passo += 1
           # ----
           # ##Passo: UCODs
           od = passo_ucods(passo, od)
           passo += 1
           # ----
           # ##Passo: "ZONA_DOM"
           od = passo_zona_dom(passo, od)
           passo += 1
```

```
# ----
# ##Passo: "SUBZONA_DOM"
od = passo_subzona_dom(passo, od)
passo += 1
# ----
# ##Passo: "MUN_DOM"
od = passo_mun_dom(passo, od)
passo += 1
# ----
# ##Passo: "F_DOM"
od = passo_f_dom(passo, od)
passo += 1
# ----
# ##Passo: "FE_DOM"
od = passo_fe_dom(passo, od)
passo += 1
# ----
# ##Passo: "TIPO_DOM"
od = passo_tipo_dom(passo, od)
passo += 1
# ----
# ##Passo: "TOT_FAM"
od = passo_tot_fam(passo, od)
passo += 1
# ----
# ##Passo: "F_FAM"
od = passo_f_fam(passo, od)
passo += 1
# ----
# ##Passo: "FE_FAM"
od = passo_fe_fam(passo, od)
passo += 1
# ----
# ##Passo: "COND_MORA"
od = passo_cond_mora(passo, od)
passo += 1
# ----
# ##Passo: "QT_AUTO"
od = passo_qt_auto(passo, od)
passo += 1
# ----
# ##Passo: "QT_BICI"
od = passo_qt_bici(passo, od)
passo += 1
```

```
# ----
# ##Passo: "QT_MOTO"
od = passo_qt_moto(passo, od)
passo += 1
# ----
# ##PASSO: "REN_FAM"
od = passo_ren_fam(passo, od, deflator)
passo += 1
# ----
# ##Passo: "CD_RENFAM"
od = passo_cd_renfam(passo, od)
passo += 1
# ----
# ##Passo: "F_PESS"
od = passo_f_pess(passo, od)
passo += 1
# ----
# ##Passo: "FE_PESS"
od = passo_fe_pess(passo, od)
passo += 1
# ----
# ##Passo: "SIT_FAM"
od = passo_sit_fam(passo, od)
passo += 1
# ----
# ##Passo: "IDADE"
od = passo_idade(passo, od)
passo += 1
# ----
# ##Passo: "SEXO"
od = passo_sexo(passo, od)
passo += 1
# ----
# ##Passo: "GRAU_INSTR"
od = passo_grau_instr(passo, od)
passo += 1
# ##Passo: "OCUP"
od = passo_ocup(passo, od)
passo += 1
# ----
# ##Passo: "SETOR_ATIV"
od = passo_setor_ativ(passo, od)
```

```
passo += 1
# ##Passo: "REN_IND"
od = passo_ren_ind(passo, od, deflator)
passo += 1
# ##Passo: "CD RENIND"
od = passo_cd_renind(passo, od)
passo += 1
# ----
# ##Passo: "F_VIAG"
od = passo_f_viag(passo, od)
passo += 1
# ----
# ##"FE_VIAG"
od = passo_fe_viag(passo, od)
passo += 1
# ----
# ##Passo: "ZONA_ESC"
od = passo_zona_esc(passo, od)
passo += 1
# ----
# ##Passo: "SUBZONA_ESC"
od = passo_subzona_esc(passo, od)
passo += 1
# ----
# ##Passo: "MUN_ESC"
od = passo_mun_esc(passo, od)
passo += 1
# ----
# ##Passo: "ESTUDA"
# Este passo deve vir após os passos de localização da escola
od = passo_estuda(passo, od)
passo += 1
# ----
# ##Passo: "ZONA_TRAB1"
od = passo_zona_trab1(passo, od)
passo += 1
# ##Passo: "SUBZONA_TRAB1"
od = passo_subzona_trab1(passo, od)
passo += 1
# ----
# ##Passo: "MUN_TRAB1"
od = passo_mun_trab1(passo, od)
```

```
passo += 1
# ----
# ##Passo: "ZONA_TRAB2"
od = passo_zona_trab2(passo, od)
passo += 1
# ----
# ##Passo: "SUBZONA_TRAB2"
od = passo_subzona_trab2(passo, od)
passo += 1
# ----
# ##Passo: "MUN_TRAB2"
od = passo_mun_trab2(passo, od)
passo += 1
# ----
# ##Passo: "ZONA_ORIG"
od = passo_zona_orig(passo, od)
passo += 1
# ----
# ##Passo: "SUBZONA_ORIG"
od = passo_subzona_orig(passo, od)
passo += 1
# ##Passo: "MUN_ORIG"
od = passo_mun_orig(passo, od)
passo += 1
# ----
# ##Passo: "ZONA_DEST"
od = passo_zona_dest(passo, od)
passo += 1
# ----
# ##Passo: "SUBZONA_DEST"
od = passo_subzona_dest(passo, od)
passo += 1
# ##Passo: "MUN_DEST"
od = passo_mun_dest(passo, od)
passo += 1
# ----
# ##Passo: "SERV_PAS_ORIG"
od = passo_serv_pas_orig(passo, od)
passo += 1
# ----
# ##Passo: "SERV_PAS_DEST"
```

```
od = passo_serv_pas_dest(passo, od)
passo += 1
# ----
# ##Passo: "MOTIVO_ORIG"
od = passo_motivo_orig(passo, od)
passo += 1
# ----
# ##Passo: "MOTIVO_DEST"
od = passo_motivo_dest(passo, od)
passo += 1
# ----
# ##Passo: "MODO1"
od = passo_modo1(passo, od)
passo += 1
# ----
# ##Passo: "MODO2"
od = passo_modo2(passo, od)
passo += 1
# ----
# ##Passo: "MODO3"
od = passo_modo3(passo, od)
passo += 1
# ----
# ##Passo: "MODO4"
od = passo_modo4(passo, od)
passo += 1
# ----
# ##Passo: "MODO_PRIN"
od = passo_modo_prin(passo, od)
passo += 1
# ----
# ##Passo: "TIPO_VIAG"
od = passo_tipo_viag(passo, od)
passo += 1
# ----
# ##"H_SAIDA"; "MIN_SAIDA"; "ANDA_ORIG"; "H_CHEG"; "MIN_CHEG";
# "ANDA_DEST"; "DIST_VIAG" e "DURACAO"
# Nada há que se fazer em relação aos dados das colunas acima mencionadas
# ##Passo: "TIPO_EST_AUTO"
od = passo_tipo_est_auto(passo, od)
passo += 1
# ----
```

```
od = passo_valor_est_auto(passo, od, deflator)
           passo += 1
            # ##Passo: Coordenadas
            od = coordenadas(passo, od)
            passo += 1
            ## O passo TOT_VIAG apenas é chamado após a geração dos IDs.
            # ##Passo: Gerando NO's e ID's
            od = gera_nos_e_ids(passo, od)
            passo += 1
            # ##Passo: "TOT_VIAG"
            od = passo_tot_viag(passo, od)
           passo += 1
            # ----
            # ##Passo: "CD_ENTRE"
            od = passo_cd_entre(passo, od)
           passo += 1
            # ----
            # ##Passo: Correções
            od = passo_correcoes(passo, od)
            passo += 1
            log_tela.info('Salvando dataframe como arquivo CSV')
            # ## Salvando o dataframe num arquivo local
            od.to_csv('outputs/1997_od.csv', sep=';', decimal=',', index=False)
            log_tela.info("Base gerada. Arquivo: outputs/1997_od.csv")
            log_tela.info("Tempo total de execução: %s segundos" %
                                (time.time() - start_time))
            log_tela.info("Horário de finalização: %s" %
                                (time.strftime("%H:%M", time.localtime(time.time()))))
            log_tela.info("Terminou o main")
    RUN the main() function....
In [ ]: if __name__ == "__main__":
           main()
```

##Passo: "VALOR_EST_AUTO"